ВТБ Титульный спонсор

ФИНАНСОВЫЙ УНИВЕРСИТЕТ

SERVICE-360

«Эффективность 360» — внутренние заявки с проверкой по регламенту

Команда

ДГ

Дмитрий Грибанов

Капитан

ГА

Гульнара Абдрахманова

Участник

ВК

Вероника Кривых

Участник

Распределение ролей

Предлагаемое распределение для команды из трёх человек. Обязанности и доступные часы закрепляются внутри команды. Роль Вероники предложена исходя из незакрытых потребностей проекта.

Дмитрий

Технический лидер · Backend и инфраструктура

Результат к сдаче: Работающий сервис, воспроизводимый запуск и схема архитектуры

- Обеспечить Docker-запуск, доступность стенда и устранение технических блокеров.
- Подготовить техническую часть защиты; ограничить Gleam-эксперимент проверяемыми задачами.

Гульнара

ИИ и бизнес-правила · QA и координация

Результат к сдаче: Проверенные правила, отчёт качества, приёмка и демо-видео

- Получить действующее положение; сверить смысл требований, условий и цитат.
- Подготовить размеченные примеры и измерить живую модель отдельно от эвристик.
- Проверить основной путь и отказные сценарии; собрать видео и комплект сдачи.

Вероника

CustDev и аналитика · Содержание защиты

Результат к сдаче: Исследование, метрики, расчёт эффекта и презентация

- Организовать интервью, согласия, опрос и выгрузку ответов.
- Заполнить гипотезы результатами; посчитать базовые время и возвраты, подготовить экономику.
- Найти контакт для пилота и собрать содержание презентации по полученным данным.

Доступ к респондентам и часть интервью обеспечивают все. Гульнара помогает сверять слайды с реализацией, Дмитрий готовит технические доказательства. Гульнару предлагается назначить координатором сдачи, Дмитрия — владельцем технического решения.

Service-360 — что это

ВТБ Титульный спонсор

Финансовый университет

Service-360 превращает свободный текст обращения сотрудника в комплектную внутреннюю заявку, проверенную по действующему положению организации, и даёт руководителю аналитику причин возвратов.

Продукт

Service-360 / «Эффективность 360»

Назначение

Оформление внутренних заявок (стартовый сценарий — служебная командировка) с проверкой полноты по утверждённому регламенту.

Ценностное предложение

Меньше возвратов «из-за неполноты», прозрачные основания каждого требования, отделяемость LLM-предложений от детерминированных правил.

Сквозной сценарий

1. **Свободный текст обращения** →
2. **Извлечение полей** →
3. **Уточнение с цитатой** →
4. **Отправка заявки** →
5. **Учёт в аналитике**

Проблема

Сотрудники тратят время на поиск требований, а исполнители — на одинаковые возвраты; обе стороны теряют часы из-за неполноты, которая не была обнаружена заранее.

Сотрудник не знает заранее, какие поля обязательны для конкретной заявки и почему.

Заявитель

Возвраты «из-за неполноты» — повторяющиеся и предсказуемые.

Возвраты

Исполнитель тратит рабочее время на одни и те же уточнения.

Исполнитель

Руководитель не видит, какие именно правила регламента вызывают больше всего возвратов.

Руководитель

Решение

Свободный текст на русском языке превращается в структурированную заявку; система задаёт только недостающие вопросы и приводит дословную цитату положения как основание требования.

- Чат → классификация типа заявки → извлечение полей.
- Детерминированная проверка полноты по утверждённым требованиям (без LLM).
- Уточнения показывают пункт положения и точную цитату.

Принцип: LLM предлагает, детерминированный код решает

- Неполную заявку отправить нельзя (422 + список недостающих полей).
- Возврат исполнителем требует указания причины; причина фиксируется в аналитике.

Ценность для организации

Эффект — не «автоматизация ради автоматизации», а прозрачность: видно, какие правила и почему вызывают возвраты, и можно менять регламент точечно.

Что получает организация

- Прозрачность оснований: каждое требование ссылается на пункт положения.
- Управляемость регламента: аналитика по причинам возвратов помогает находить спорные или устаревшие правила.
- Снижение нагрузки на исполнителя за счёт автоматической проверки.

Гипотезы — нужен пилот

- Снижение числа возвратов из-за неполноты.
- Сокращение времени одного цикла уточнения — нужен замер.

гипотеза, требует пилота

Сценарии использования

Четыре роли — четыре задачи; один и тот же сценарий «заявка на командировку» проходит через все роли без переключения систем.

Заявитель

Свободный текст → уточнения с цитатами → отправка → статус в личном кабинете и уведомления.

демо v0.1

Исполнитель

Очередь своего подразделения → карточка заявки → принять в работу / вернуть с причиной / закрыть.

v0.2

Руководитель

Агрегаты по типам заявок, доля закрытых без возврата, среднее время этапов, причины возвратов (без имён заявителей).

демо → live v0.2

Администратор

Загрузка положения DOCX/PDF/TXT → разбор на требования → редактирование и утверждение версии (v0.2).

v0.2

Технологическая архитектура

Архитектура разделена на «детерминированный код» (полнота, статусы, права) и «ИИ-слой» (классификация, извлечение); состояние хранится в PostgreSQL, события доставляются через NATS JetStream.

Текущий репозиторий: Gleam-вариант

Gleam/Wisp API → PostgreSQL (10 таблиц + job_runs + outbox) → Go outbox-relay → NATS JetStream.

Dockerfile API: Erlang 28 + Gleam 1.19.2; relay: Go 1.26 + distroless.

Consumer/callback пока не реализован — сообщения публикуются, но не обрабатываются.

эксперимент

Основная конкурсная версия

React → FastAPI → PostgreSQL → LLM-слой → детерминированная проверка правил.

46 локальных тестов прошли; 22 HTTPS API-проверки на Python 3.12 + PostgreSQL 16.

основная версия

Общее

- LLM-провайдер — локальный (Ollama-first с OpenAI-compatible адаптерами, миграция с Mellum).
- Детерминированный policy engine.
- PII-редекция перед LLM.
- Аудит append-only.

две реализации

Текущая готовность

В Gleam-репозитории работает инфраструктурный вертикальный срез: API принимает заявки, БД хранит состояние, relay публикует события. Полный сценарий A и UI — в плане.

Работает

- PostgreSQL: схема из 10 таблиц + job_runs + outbox; миграция применена.
- Docker-образы API и outbox-relay собираются.
- Compose-стек (postgres, nats, api, outbox-relay) с healthcheck.
- /health, /ready; идемпотентный POST /api/v1/requests; outbox-publish requests.created в NATS JetStream с MsgId.
- Citation validator: 23/23 unit-тестов.
- Python-версия: 46 локальных тестов, 22 HTTPS API-проверки, путь «запрос → грант → PDF → исполнитель → в работе → исполнена».

проверено

Stub

Go consumer + classifier/extraction + LLM-адаптеры (Ollama/OpenAI-compat) + PII-редекция.

Качество на demo-fixture: классификация 83%, extraction 50% — честные числа на синтетике, не на живой модели.

собрано, но stub

Не реализовано

Consumer/callback с реальной LLM, чат/UI (React + TS + Vite), deterministic completeness в production-коде, eval harness, Auth/RBAC/JWT/CSRF, dashboard, admin-загрузка положения, реальный браузерный E2E.

request_type.enabled = false: цитаты ПП РФ № 501 в fixture — TODO-плейсхолдеры.

план

Результаты и подтверждения

Подтверждено инфраструктурой, проверками и stub-реализациями; не подтверждено реальными пользователями и живой LLM.

Подтверждено

Технические проверки

- Gleam-каркас: 4 smoke-проверки API, миграция применена, idempotency, publish в NATS JetStream.
- Python-версия: 46 локальных тестов; 22 HTTPS API-проверки; путь «заявка → исполнение» проверен через API.
- Unit-тесты: citation validator 23/23; localllm 14; pii 3; LLMClassifier 4; jobhandler; extractor — итого 41 Go-тест OK.

Прототипы и CustDev

- Методика CustDev: 10 интервью (4 заявителя + 4 исполнителя + 2 владельца), протокол наблюдения за прототипом, таблица инсайтов.
- Desk-research: 9 независимых источников; гипотезы H1–H6 — PARTIALLY VALIDATED / NOT VALIDATED, честный статус, не «подтверждено».

Не подтверждено

- Eval harness с живой LLM на независимых примерах — не выполнено.
- Браузерный E2E с реальными пользователями без подсказок — не проведён.
- Пилот в конкретном подразделении — не начат (нет контакта, договорённости, замера затрат).

нужны замеры

План развития

До v0.1 (31.10.2026) — закончить сценарий A и citation validation; до v0.2 (28.11.2026) — кабинет исполнителя и дашборд; до пилота (07.12.2026) — реальный контакт и замер.

v0.1 — прототип

до 31.10.2026

- Дословное заполнение business_trip_fixture.json цитатами ПП РФ № 501 и citation validation = PASS (владелец — Гульнара).
- Consumer/callback с реальной LLM для requests.created.
- Deterministic completeness (policy engine) для сценария A.
- Минимальный UI (чат + draft), mobile 360px, auth/RBAC baseline, audit_log.
- Eval-датасет + make eval, dashboard на демо-данных, видео 2–3 мин, репетиция.

v0.2 — MVP

до 28.11.2026

- Кабинет исполнителя: очередь, accept/return с причиной, close (F7).
- Email/webhook-уведомления (F6 outbound).
- Live-дашборд с CSV-экспортом (F8).
- Admin: загрузка положения DOCX/PDF/TXT + edit/version/approve (F9).
- Telegram-бот поверх того же API (F10).

Пилот

до 07.12.2026

- Контакт пилотного подразделения, договорённость.
- Замер затрат и расчёт экономики.
- CustDev-eval на 5+ пользователях без подсказок.

Риски

- Реалистичность срока 31.10 при текущей ёмкости команды требует подтверждения на СР3.
- Mellum/Ollama on-prem — нужна проверка реального развёртывания.
- Две расходящиеся реализации (Python vs Gleam) усложняют развитие.
- glats 0.9.1 ниже 1.0; в v0.1 используется только Go-клиент через outbox relay.

Инвестиционный тезис

Продукт решает повторяемую боль (неполнота заявок), архитектура зрелая и разделена правильно, но до инвестиционного решения нужны независимые доказательства — пилот, метрики CustDev, прогон живой LLM.

Потенциал

Повторяемая боль в любой организации с регламентами; LLM делает извлечение полей дешёвым, детерминированный код сохраняет доверие к требованиям.

Ожидаемая ценность (гипотеза, не измерено): снижение возвратов из-за неполноты, сокращение цикла уточнения, разгрузка исполнителей, аналитика для пересмотра регламента. Требует пилота.

повторяемая боль

Масштабирование

Сценарии A → B → C → D (другие типы заявок), новые подразделения, новые регламенты. LLM-провайдер заменяемый, типы заявок конфигурируемые, основания прозрачны.

Ближайшие контрольные точки

- 31.10.2026 — закрытый сценарий A с дословными цитатами ПП № 501.
- 28.11.2026 — MVP с кабинетом исполнителя и live-дашбордом.
- 07.12.2026 — договорённость о пилоте в одном подразделении и расчёт затрат.

зрелая архитектура

Что нужно подтвердить

- Метрики CustDev (≥10 интервью, доля возвратов, время цикла).
- Прогон живой LLM (Ollama/YandexGPT/GigaChat/Mellum) на независимых примерах — accuracy ≥90%, extraction recall ≥85%.
- Пилот в одном подразделении с владельцем, согласовавшим доступ к документам.
- Расчёт затрат на внедрение и владение.

нужны замеры